

Adestramento de Modelos de IA

AdaBoost & GAN nun Sistema de Detección de Intrusións

Práctica 2 – Ciberseguridade e Protección da Información

Laura Cabaleiro Pintos Pablo Chantada Saborido

Marcelo Ferreiro Sánchez José Romero Conde

Curso 2025–2026

- 1 Análise e Preprocesado do Dataset
- 2 Modelo Complexo: GAN
- 3 Modelo Base: AdaBoost Binario
- 4 Modelo Base: AdaBoost Multiclase
- 5 Experimento de Data Augmentation
- 6 Comparativa e Conclusións

- 1 Análise e Preprocesado do Dataset
- 2 Modelo Complexo: GAN
- 3 Modelo Base: AdaBoost Binario
- 4 Modelo Base: AdaBoost Multiclase
- 5 Experimento de Data Augmentation
- 6 Comparativa e Conclusións

Orixe e Calidade Básica

- Dataset orixinal: **CIC-IDS2017** (TrafficLabelling)
- **Nulos e Infinitos:** Moi escasos (1 358 NaNs e 1 509 Infs). Elimináronse as filas directamente dado o volume de datos (~3M)

Resultado da limpeza (fluxos)

3 119 345 iniciais $\Rightarrow$ 2 827 876 útiles

Risco de Fuga de Información

- Retiráronse identificadores puros (FlowID) e variables de contexto temporal/xeográfico (IPs, Timestamp)
- Obxectivo: conseguir que a rede xeralize, en vez de aprender o dataset

Columnas Duplicadas e Bugs de CICFlowMeter

- Detectáronse variables con información idéntica debido a erros de captura do software
 - Ex: `TotalFwdPackets` $\equiv$ `SubflowFwdPackets`
 - Columnas de tipo Bulk rexistradas sempre a cero
 - Variables PSH/URG en dirección *backward* sempre a cero
- ⇒ Elimináronse todas as redundancias e columnas mortas

Impacto

Sen esta limpeza, os modelos aprenderían **artefactos** do software de captura, non patróns reais de tráfico

Distribucións Power-Law

- As variables numéricas de rede (conteo de paquetes, duración, taxa de bytes) **non seguen unha distribución normal**.
- Amosan comportamento tipo *power-law* (liña recta en escala log-log) ou multimodalidade pola MTU (Figura 1).
- O uso de límites estatísticos comúns (Z-score, IQR estrito) eliminaría patróns reais de ataques masivos.

Tratamento Físico de Valores

- ➊ **Tratamento de tempos negativos:** Fixáronse en 0 os tempos rexistrados en negativo.
- ➋ **Truncamento por Overflow:** Variables con máximos disparados pola ferramenta (ex. `TotalLengthofBwdPackets`) limitáronse ao percentil 99.
- ➌ **Mantemento de anomalías:** Extremos en `FlowBytes/s` *non* se tocaron por ser evidencia real de DDoS.
- ➍ **Normalización:** Uso de `RobustScaler` (baseado na mediana e IQR) fronte a escaladores estritos.

Escala lineal VS Escala Log-Log





Figura: Escala lineal VS Escala log-log

Codificación Categórica (One-Hot)

- **Protocolos:** Representados como columnas independentes (TCP, UDP, Outros).
- **Portos:**
 - Illáronse os **21 portos máis críticos** observados en ataque e tráfico (ex: 22, 53, 80, 443, 8080).
 - Os miles de portos dinámicos restantes colapsáronse na categoría '*Outro*'.
 - Mantense o sinal de ataque previndo a explosión dimensional.

Redución Dimensional (PCA)

- Tras codificar as categóricas e normalizar, avalíase a correlación (Figura ??).
- Obsérvase gran solapamento e redundancia entre variables estatísticas (*Mean, Std, Max*).
- **Aplicouse PCA** retendo a compoñente de varianza principal e eliminando o ruído solapado.

Espazo Final de Entrada

52 variables predictoras
representativas de todo o fluxo.

Top 10 features por varianza



Desbalanceo de Clases e Mostraxe Final

O Problema do Desbalanceo

- **Escenario Binario:** 80,3 % de mostrás BENIGN vs 19,7 % de ATTACK (Ratio 4:1).
- **Escenario Multiclase:** Desbalanceo abismal de ata 200 000:1 nas clases específicas.
- Clases de ataque precisas (ex. *Heartbleed*: 11 mostrás; *SQL Injection*: 21 mostrás) quedarían absorbidas pola maioría e invisibilizadas no modelo.

Estratexia de Mostraxe Híbrida

Para acadar o dataset definitivo (Práctica 2) empregouse:

- 1 **Undersampling:** Recorte xeneralizado do tráfico maioritario lexítimo.
- 2 **SMOTE:** *Oversampling* sintético para dar volume estocástico ás clases minoritarias, evitando o sobreaxuste simple.


Dataset de Traballo (Práctica 2)

182 000 mostrás



Split estratificado 70/15/15:

Train: 127 400 | Val: 27 300 | Test: 27 300


Dataset Pre-Procesado






Multiclase — Proporción (Top 8 + Other)




Binario — BENIGN vs ATTACK (proporción)



Dataset Post-Procesado



Binario — BENIGN vs ATTACK (proporción)



- 1 Análise e Preprocesado do Dataset
- 2 **Modelo Complexo: GAN**
- 3 Modelo Base: AdaBoost Binario
- 4 Modelo Base: AdaBoost Multiclase
- 5 Experimento de Data Augmentation
- 6 Comparativa e Conclusións

Evolución do enfoque:


- 1 GAN como detector de anomalías
(adestrando só con BENIGN)
- 2 Segunda variante probando adestramento con máis mostras malignas
- 3 **Versión final: formulación adversaria híbrida**

Versión final (Figura 15)


- **Discriminador:** Optimizouse usando etiquetas reais binarias (BENIGN/ATTACK) e introducindo mostras sintéticas (cunha *label*=0 artificial).
- **Xerador:** Optimizouse xerando patróns e enganando ao discriminador forzándoo a prever *label*=1.

Arquitectura GAN

Adestramento Discriminador



Adestramento Xerador



GAN – Resultados Binarios

Métricas sobre test

Accuracy	0,9327
Precision	0,9273
Recall	0,9844
F1-score	0,9550
AUC-ROC	0,9544

Adestramento (440 épocas)


- **AUC-ROC val. máx.:** 0,9499 (época 310)
- **Accuracy val. máx.:** 0,9300 (época 388)
- **Dinámica adversaria:** a perda do discriminador diminúe progresivamente mentres a do xerador oscila e tende a aumentar.

Matriz de confusión (test)


	Pred. Normal	Pred. Ataque
Normal	5 971	1 529
Ataque	308	19 492

O recall amósase moi alto en ATTACK (só 308 Falsos Negativos). Os 1 529 Falsos Positivos considéranse aceptables nun NIDS: un sistema de detección penaliza moito máis o feito de non alertar ante tráfico malicioso.

Curva AUC-ROC - GAN Binaria



Accuracy Validation - GAN Binaria



GAN – Clasificación Multiclase

Métricas sobre test (one-vs-rest)

Accuracy	0,6976
Precision macro	0,8912
Recall macro	0,6814
F1 macro	0,7032
F1 weighted	0,7409
AUC-ROC media	0,966

Clases perfectamente illadas (AUC=1.0)

Bot, FTP-Patator, Heartbleed, SSH-Patator


AUC-ROC por clase (selección)

Clase	AUC-ROC
Bot	1,0000
FTP-Patator	1,0000
Heartbleed	1,0000
SSH-Patator	0,9999
DDoS	0,9983
PortScan	0,9926
Web Attack - XSS	0,9228
DoS Slowhttptest	0,9153

Dificultades detectadas

O modelo xera moita confusión e FP arredor de *DoS Slowhttptest* e *Web Attack* (XSS, Brute Force).

Curva AUC-ROC - GAN Multiclase



Accuracy Validation - GAN Multiclase



- 1 Análise e Preprocesado do Dataset
- 2 Modelo Complexo: GAN
- 3 Modelo Base: AdaBoost Binario**
- 4 Modelo Base: AdaBoost Multiclase
- 5 Experimento de Data Augmentation
- 6 Comparativa e Conclusións

Busca de hiperparámetros

- 1 Verificación de viabilidade vía *Grid Search*.
- 2 **Optimización Bayesiana Final**
Baseada en Procesos Gaussianos. Avaliáronse 15 puntos aleatorios iniciais e 40 iteracións da función de perda.

Espazo buscado:

- `n_estimators`: [15, 500]
- `learning_rate`: [0.0001, 2]

Mellores hiperparámetros (*F1 micro*)

Binario:

`n_estimators` ≈ 390
`learning_rate` $\approx 1,908$

Multiclase:

`n_estimators` ≈ 434
`learning_rate` $\approx 0,706$

Trala converxencia, os puntos concentráronse sistematicamente na zona de un *learning rate* alto xunto a un empaquetamento de estimadores medio-alto.

AdaBoost – Resultados

Clasificación binaria (test)

Accuracy	0,9144
Recall ATTACK	0,98
Recall BENIGN	0,73
F1 micro	0,9144
AUC-ROC	0,9474

Clasificación multiclase (test)

Accuracy	0,65
Precision macro	0,58
Recall macro	0,45
F1 macro	0,47
F1 weighted	0,62
AUC-ROC media	0,9215


Matriz de confusión binaria

	Pred. Normal	Pred. Ataque
Normal	5 466	2 034
Ataque	302	19 498


Bo comportamiento: DDoS, PortScan, SSH-Patator (patrones de ataque masivos e sistematicos).

Problemáticas severas: Heartbleed, Web Attack
- Brute Force/XSS/SQLi terminan absorbidas case ao completo polas clases de maior representación no colector arbóreo.

Curva AUC-ROC - AdaBoost Binario



Búsqueda de Parametros - AdaBoost Binario



- 1 Análise e Preprocesado do Dataset
- 2 Modelo Complexo: GAN
- 3 Modelo Base: AdaBoost Binario
- 4 Modelo Base: AdaBoost Multiclase**
- 5 Experimento de Data Augmentation
- 6 Comparativa e Conclusións


Métricas sobre test (one-vs-rest)

Accuracy	0,65
Precision macro	0,58
Recall macro	0,45
F1 macro	0,47
F1 weighted	0,62
AUC-ROC media	0,9215


Análise de Rendemento

- **Bo comportamento:** DDoS, PortScan e SSH-Patator (patróns de ataque masivos e sistemáticos).
- **Problemáticas severas:** Heartbleed e Web Attack (Brute Force, XSS, SQLi).
- **Xustificación:** Ao estar o modelo baseado nun colector de árbores, as clases con moi poucas mostras rematan absorbidas case ao completo polas clases de maior representación lexítimas.

Curva AUC-ROC - AdaBoost Multiclase



Búsqueda de Parametros - AdaBoost Multiclase



- 1 Análise e Preprocesado do Dataset
- 2 Modelo Complexo: GAN
- 3 Modelo Base: AdaBoost Binario
- 4 Modelo Base: AdaBoost Multiclase
- 5 Experimento de Data Augmentation**
- 6 Comparativa e Conclusións

Data Augmentation – A GAN como Xerador

Experimento

- Aproveitouse o *Xerador* da GAN para crear **127 400 mostrás sintéticas** adicionais.
- Dataset de adestramento pasou de 127 400 → **254 800** (os de validación e test quedaron inalterados para comparativa leal).
- Reentrenouse AdaBoost (en binario) e volveuse aplicar a busca bayesiana.

Comparativa de resultados (Acc | F1 w.)

AdaBoost base orixinal	0,9144	0,9106
AdaBoost con augmentación	0,9112	0,9078

Por que non mellora o F1?

- O *Xerador* da GAN aínda **non converxera** estatisticamente por cuestión de recursos/épocas.
- O discriminador é un gran *clasificador*, pero non implica que as mostrás sintéticas fosen da calidade suficiente.
- O efecto do volume de datos engadido foi **practicamente neutro**.

- 1 Análise e Preprocesado do Dataset
- 2 Modelo Complexo: GAN
- 3 Modelo Base: AdaBoost Binario
- 4 Modelo Base: AdaBoost Multiclase
- 5 Experimento de Data Augmentation
- 6 Comparativa e Conclusións

Comparativa Cuantitativa Global

Escenario Binario

Modelo	Acc.	Prec.	Recall	F1	AUC-ROC
AdaBoost	0,9144	0,91	0,98	0,94	0,9474
AdaBoost + augmentado	0,9112	0,91	0,98	0,94	0,9477
GAN	0,9327	0,9273	0,9844	0,9550	0,9544

Escenario Multiclase

Modelo	Acc.	Prec. M	Rec. M	F1 M	F1 w.	AUC-ROC
AdaBoost multiclase	0,65	0,58	0,45	0,47	0,62	0,9215
GAN multiclase	0,6976	0,8912	0,6814	0,7032	0,7409	0,9656

Conclusión obxectiva: a **GAN domina estritamente a AdaBoost** en tódalas métricas en ambos contornos, aínda que co problema inherente do custo de adestramento e os tempos computacionais.³⁴ / 37

AdaBoost – O Modelo Base

- + Enfoque veloz e estable no adestramento.
- + Excelente aliación coa optimización bayesiana.
- + Gran capacidade de explicabilidade algorítmica.
- + Métricas *recall* fortísimas en ataques.
- Rendemento multiclase moi baixo e limitado.
- Aniquilación analítica de clases minoritarias.

GAN – O Enfoque Complexo

- + Superioridade incuestionable nas métricas finais.
- + AUC-ROC media multiclase colosal (0,966).
- + Viabilidade inherente para usar redes como xeradores.
- Adestramento criticamente lento e inestable (oscilatorio).
- *Data augmentation* actual neutral polas épocas.

Traballo Futuro

- Construción de **GANs Condicionais independentes por clase** para illar os ataques residuais.
- Ampliación masiva de épocas de cómputo ata asentar a verdadeira converxencia estatística do *Xerador*.
- Exportación exitosa do dataset da GAN para o reaxuste robusto noutros modelos.

Grazas pola atención

Laura Cabaleiro Pintos
Pablo Chantada Saborido
Marcelo Ferreiro Sánchez
José Romero Conde

Práctica 2 – Ciberseguridade e Protección da Información
Curso 2025–2026